

Relatório Crítico — Chatbot Especialista em Edifícios Verdes / Net Zero

GS 2026.1 — Space Connect · Disciplina de NLP

Aluno: Moacyr Cabral da Silva — RM 559263

Execução de referência: Google Colab (GPU T4), 942 pares de treino, fine-tuning QLoRA de 112 passos (2 épocas), loss de treino 2,66 → 0,70. Resultados completos em `relatorios/avaliacao_resultado.json`.

1. Dificuldades na coleta e preparação dos dados

Documento digitalizado no corpus. O candidato inicial de relatório técnico de energia — o *Balanço Energético Nacional* da EPE — revelou-se um PDF digitalizado (imagens de infográficos), com extração de apenas ~35 caracteres por página contra 1.500–2.400 dos demais. Como o enunciado pede que se preservem tabelas e requisitos numerados, e um texto desse tipo só entraria via OCR de baixa qualidade, o documento foi **descartado** e o corpus seguiu com 14 documentos (acima do mínimo de 10, com as três categorias mantidas). Lição: a verificação de um PDF não pode parar no HTTP 200 e no *content-type*; é preciso medir a densidade de texto extraível antes de aceitá-lo.

Desequilíbrio de volume entre documentos. O Manual de Engenharia Fotovoltaica (CRESESB, 530 páginas) sozinho gera ~495 passagens — quase um terço do corpus —, o que enviesaria os pares de treino para energia solar. Mitigação: a geração de Q&A aplica um **teto por documento** (amostragem espaçada de no máximo 60 passagens/documento), para que normas de água e certificações não fossem ofuscadas.

Ruído estrutural dos PDFs técnicos. Cabeçalhos/rodapés repetidos, numeração de página e hifenização de fim de linha exigiram limpeza. O cuidado central foi **não remover requisitos normativos numerados** (ex.: "4.39 Edificação de energia quase zero"), que à primeira vista parecem numeração de página mas carregam o conteúdo técnico. A regra de limpeza distingue "linha só com dígitos" de "item normativo".

Escolha do gerador dos pares Q&A. Optou-se por gerar os pares com o **próprio Llama 3.2 3B** (sem LLM externo). O risco conhecido é a circularidade — treinar o modelo nas suas próprias saídas — e a alucinação de números normativos. Mitigação adotada: geração **extrativa e grounded** (temperatura 0.3, ancorada em cada passagem) e uma **verificação anti-alucinação** que descarta respostas cujos números/percentuais não aparecem na passagem de origem. O total de pares rejeitados por essa verificação está em `relatorios/qa_geracao.md` e é, por si, um indicador da propensão do modelo base a inventar.

2. Impacto do fine-tuning (modelo base vs. ajustado)

A avaliação (notebook §7) compara as respostas do modelo base e do ajustado às mesmas 10 perguntas

técnicas (`relatorios/perguntas_referencia.json`), cobrindo energia, água e certificações.

Modelo	BERTScore F1
Base (Llama 3.2 3B, sem ajuste)	0,6898
Ajustado (QLoRA)	0,7123
Δ (ajustado – base)	+0,0225

O fine-tuning produziu um **ganho consistente e na direção esperada**: as respostas do modelo ajustado ficaram semanticamente mais próximas das referências escritas pelo aluno. O ganho é **modesto em magnitude** (+2,25 pontos de F1), compatível com o que se pode esperar de um adaptador LoRA sobre um modelo de 3B treinado com ~900 pares sintéticos — e a curva de perda caindo de 2,66 para 0,70 confirma que houve aprendizado efetivo, sem sinais de divergência.

Onde o ganho se manifestou (estilo e formato). O efeito mais visível do ajuste foi de **aderência ao domínio e ao formato de resposta**: o modelo ajustado responde de forma mais direta e no registro técnico do corpus, em vez do tom genérico do modelo base. É isso que o BERTScore captura e premia.

Onde o ganho NÃO se manifestou (correção factual) — análise honesta. Inspeccionando as respostas do modelo ajustado uma a uma, persistem **erros factuais graves**, que é fundamental reconhecer:

- **NBR da água de chuva**: o modelo respondeu "*ABNT NBR 15548*" — o número correto é **NBR 15527**. Alucinação de um identificador normativo.
- **Águas cinzas**: respondeu que resultam "*da coleta de águas pluviais e de chuva*" — **conceito trocado**: águas cinzas vêm de banho e máquina de lavar; água de chuva é outra categoria (água pluvial). O modelo fundiu os dois temas do corpus.
- **Níveis do LEED**: respondeu "*Plata, Prata, Ouro e Diamante*" — os níveis corretos são Certified, Silver, Gold e **Platinum**. "Diamante" não existe e há redundância ("Plata"/"Prata").
- **NZEB**: a resposta foi curta e circular ("é um critério mínimo de geração renovável"), sem chegar ao critério de **50% da demanda anual** que está no corpus.

Ou seja: o ajuste melhorou a **forma** mais do que o **conteúdo factual**. Isso é coerente com a natureza do treino (ver seção 3 sobre o limite da métrica e seção 4 sobre as causas).

3. Análise das métricas

O **BERTScore** foi escolhido em vez de BLEU/ROUGE-L por operar no espaço de embeddings semânticos — mais adequado a respostas técnicas em português, que podem estar corretas com fraseado diferente da referência.

Limitação da métrica, confirmada na prática. O BERTScore mede **similaridade semântica com a referência**, não **correção factual** — e este experimento é uma ilustração didática disso. A resposta sobre a NBR da água de chuva ("*ABNT NBR 15548 — Aproveitamento de água de chuva em edificações*") é **lexicalmente quase idêntica** à referência ("*ABNT NBR 15527... aproveitamento de água de chuva... fins não potáveis*"): mesmo tema, mesma estrutura, mesma terminologia. O BERTScore a pontua alto, **apesar do número da norma estar errado**. Isso explica por que o F1 pode subir (+0,0225) enquanto erros factuais

persistem: a métrica recompensa o modelo por "falar como o corpus", que foi exatamente o que o fine-tuning ensinou.

Conclusão metodológica: para um assistente normativo, BERTScore é um indicador **necessário mas não suficiente**. Uma avaliação completa exigiria uma verificação factual dedicada (checar se o número da norma/percentual citado bate com a fonte) — o que se conecta à melhoria proposta nº 2.

4. Limitações do modelo ajustado

- **Circularidade dos dados de treino (causa principal dos erros factuais).** Os pares Q&A foram gerados pelo próprio Llama 3.2 3B. A verificação anti-alucinação descarta respostas com **números** ausentes na passagem, mas **não valida fatos não-numéricos** (qual norma, qual conceito). Assim, erros como trocar NBR 15527 por "15548" ou confundir águas cinzas com água de chuva podem entrar no conjunto de treino e ser reforçados — o modelo aprende a "soar correto" sem garantia de "ser correto".
- **Escala do modelo (3B):** capacidade de raciocínio e retenção factual limitadas; perguntas que exigem cruzar vários requisitos produzem respostas incompletas ou circulares (caso do NZEB, em que o modelo não chegou ao critério de 50%).
- **Cobertura e desequilíbrio do corpus:** 14 documentos não esgotam o domínio, e a distribuição é desigual (energia domina; só 88 chunks de relatórios técnicos). Temas pouco representados terão respostas mais fracas.
- **Sem rastreabilidade da fonte:** o fine-tuning incorpora conhecimento nos pesos, mas o modelo não cita de onde tirou a informação — o que agrava o risco quando ele erra, pois a resposta errada vem com o mesmo tom de confiança de uma correta.

5. Melhorias propostas (com mais tempo/recursos)

1. **Gerador de Q&A mais forte + curadoria humana + verificação factual.** A causa-raiz dos erros (seção 4) é a circularidade do treino. Gerar os pares com um modelo maior (ex.: Llama 70B via provedor de inferência) e adicionar uma verificação factual que valide **nomes de normas e conceitos** (não só números) contra o corpus elevaria diretamente a correção — atacando os casos NBR 15527, LEED e águas cinzas.
2. **Acoplar recuperação (RAG) ao modelo ajustado.** O sistema já tem o corpus indexado em ChromaDB (`src/retriever.py`). Combinar o modelo ajustado com a recuperação dos trechos relevantes a cada pergunta colocaria o número/conceito correto **na frente do modelo no momento da resposta**, corrigindo justamente as alucinações observadas, e ainda traria **rastreabilidade da fonte** — o tipo de auditoria que a disciplina de Governança valoriza. Mediria-se também a *faithfulness* (resposta ancorada no trecho).
3. **Expandir e equilibrar o corpus** (NBR 15575, material de BEMS, mais relatórios técnicos para reduzir o desequilíbrio de 88 chunks da categoria) e re-treinar com mais épocas sobre um conjunto curado.

Etapa 1 — Planejamento e Escopo

GS 2026.1 — Processamento de Linguagem Natural Aluno: Moacyr Cabral da Silva — RM 559263 **Tema:** Assistente para Projeto de Edifícios Eficientes quanto a Água e Energia

1. Recorte temático

O recorte adotado é o **caso integrado água + energia**, alinhado à passagem destacada do enunciado: *"de modo que o edifício seja capaz de suprir metade ou todas suas necessidades de água e energia sem depender de fontes externas"*. Restringir o assistente a apenas um dos insumos empobreceria o caso de uso real — projetistas de edifícios Net Zero precisam balancear os dois domínios simultaneamente (ex.: bombas de uma cisterna pluvial dependem do dimensionamento fotovoltaico).

Sub-temas cobertos pelo corpus:

Domínio	Sub-tema
Energia	Eficiência energética em edificações (envelope, iluminação, HVAC)
Energia	Geração distribuída por sistemas fotovoltaicos
Energia	Building Energy Management Systems (BEMS)
Água	Captação e aproveitamento de águas pluviais
Água	Reúso de águas cinzas
Transversal	Certificações ambientais (LEED, AQUA-HQE, GBC Brasil Casa, NBR 15575)
Transversal	Conceito Net Zero / Zero Energy Building (ZEB)

2. Decisões de tecnologia

2.1 Modelo base

Escolha: meta-llama/Llama-3.2-3B-Instruct

- 3,2 bilhões de parâmetros — cabe em GPU T4 (16 GB) com QLoRA 4-bit, com folga para batch size razoável.
- Treinado nativamente para conversação (variante *Instruct*), o que reduz o risco de regressão estilística após o ajuste.
- Bom desempenho em português técnico segundo benchmarks públicos da Meta (Belebele, MGSM-PT).

- Recomendado textualmente pelo enunciado.

Alternativas descartadas:

- Qwen 2.5 3B — comparável tecnicamente, sem licença-gate, mas foge da recomendação textual do enunciado.
- Phi-3.5 mini (3.8B) — bom raciocínio, PT mais fraco.
- Modelos $\geq 7B$ — não cabem em T4 free.

2.2 Modelo de embedding

Escolha: `intfloat/multilingual-e5-large`

- 1024 dimensões, 100+ idiomas, treinado especificamente para retrieval.
- Padrão de fato em RAG técnico em PT segundo o leaderboard MTEB.
- Recomendado pelo enunciado.

Alternativa considerada: `paraphrase-multilingual-mpnet-base-v2` (768 dim), mais leve mas com recall inferior em consultas técnicas longas.

2.3 Banco vetorial

Escolha: `ChromaDB` persistente.

- Persistência local em SQLite + arquivos `.bin` — sem servidor externo.
- Mesma stack já validada na disciplina de GenAI (coerência arquitetural na entrega integrada Space Connect).
- API simples para metadados estruturados (categoria, fonte, ano, vigência).

2.4 Estratégia de fine-tuning

Escolha: `QLoRA` (LoRA com base quantizada em 4 bits via `bitsandbytes`).

- LoRA puro em 16 bits demanda ~12 GB de VRAM para Llama 3B + gradientes — apertado em T4.
- QLoRA reduz a base para ~2,5 GB e libera espaço para batch size 4–8 sem OOM.
- Treina apenas o adaptador (~30–50 MB), facilitando versionamento e distribuição (Hugging Face Hub).

Hiperparâmetros previstos (sujeitos a ajuste após validação):

Hiperparâmetro	Valor	Justificativa
<code>r</code> (rank LoRA)	16	Padrão para QLoRA SFT em 3B; ganhos marginais acima disso
<code>lora_alpha</code>	32	Convenção $\alpha = 2 \cdot r$
<code>lora_dropout</code>	0.05	Pequeno, dataset não é grande o suficiente para over-regularização

Target modules	q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj	Cobertura completa das atenções e MLPs
learning_rate	2e-4	Padrão de SFT QLoRA validado pelo time HF
lr_scheduler	cosine	Suaviza convergência ao final
epochs	2–3	Datasets pequenos (≈1000 pares) tendem a overfit acima de 3 épocas
batch_size (per_device)	4	Cabe em T4 com max_seq_length=1024 em 4-bit
gradient_accumulation_steps	4	Batch efetivo de 16
max_seq_length	1024	Coberto pelos chunks (512–1024 tokens) e pelos pares Q&A
optimizer	paged_adamw_8bit	Recomendado para QLoRA, evita pico de VRAM
Quantização	4-bit NF4, double-quant	Configuração canônica QLoRA do paper original

Bibliotecas: transformers + peft + bitsandbytes + trl (SFTTrainer).

2.5 Geração dos pares Q&A

Escolha: geração sintética via LLM grande (Gemini 2.5 Flash Lite, mesma chave já configurada na disciplina de GenAI), grounded em cada chunk do corpus, com revisão por amostragem.

- Para cada chunk, prompt instrui o modelo a gerar 3–5 pares Q&A apoiados estritamente no chunk, em PT-BR, com perguntas variadas (definição, requisito numérico, comparativo, aplicação prática).
- Meta: ~1000 pares cobrindo os 10+ documentos do corpus.
- Pós-filtro automático: remoção de pares com resposta < 30 caracteres, perguntas duplicadas (Jaccard > 0.85), respostas que apenas repetem a pergunta.
- Revisão manual: amostragem aleatória de 30 pares para garantir qualidade.

2.6 Avaliação

- 10 perguntas técnicas formuladas manualmente, cobrindo todos os sub-temas do recorte (energia + água + certificações).
- Comparação **modelo base vs. modelo fine-tunado** nas mesmas 10 perguntas.
- Métrica automática: **BERTScore** (F1) em relação a respostas de referência escritas pelo aluno — mais robusta que BLEU/ROUGE para texto técnico em PT, pois opera no espaço de embeddings semânticos em vez de n-gramas.
- Análise qualitativa de cada caso: precisão factual, profundidade, aderência ao domínio.

2.7 Deploy do chatbot

Escolha: Streamlit dentro do próprio notebook Colab, exposto via `pyngrok` ou `cloudflared`.

- Após o fine-tuning, célula final do notebook carrega o adaptador, instancia o modelo e sobe a UI.
- Histórico de conversa em `st.session_state`.
- Sem dependência de máquina local com GPU para a demonstração — vídeo gravado no próprio Colab.

2.8 Ambiente de execução

Etapa		Onde roda
1. Planejamento		Local (Markdown)
2. Coleta corpus		Local (downloads + metadados)
3. Limpeza + Q&A		Local (Python + Gemini API)
4. Chunking + embeddings + Chroma		Local (CPU é suficiente para o volume)
5. Fine-tuning QLoRA		Google Colab GPU T4
6. Avaliação		Google Colab GPU T4 (precisa carregar modelo)
7. Chatbot Streamlit		Google Colab GPU T4 + ngrok
8. Relatório crítico		Local (Markdown → PDF)

3. Estrutura de entrega prevista

```
GS2026_NLP_Moacyr/
├─ relatorios/
│  └─ 01_planejamento.md          # este documento
│  └─ relatorio_final.pdf          # relatório crítico (Etapa 8)
│  └─ avaliacao.md                 # 10 perguntas: base vs. fine-tuned (Etapa 6)
├─ corpus/                         # 10+ PDFs com metadados (Etapa 2)
│  └─ metadata.json
├─ data/
│  └─ chunks.jsonl                 # chunks com metadados (Etapa 4)
│  └─ pares_qa.jsonl               # 500-1500 pares (Etapa 3)
│  └─ chroma_db/                   # vector store (Etapa 4)
├─ src/
│  └─ extrair_e_limpar.py           # pipeline de limpeza
│  └─ gerar_qa.py                   # geração sintética via Gemini
│  └─ chunking_e_index.py           # chunking + embeddings + Chroma
│  └─ avaliar.py                    # BERTScore base vs. ajustado
├─ notebooks/
│  └─ finetuning_llama_qlora.ipynb # notebook Colab (Etapas 5, 6, 7)
├─ app/
│  └─ chatbot_streamlit.py          # UI conversacional
└─ scripts/
```

	└─ baixar_corpus.py	# idempotente, com fontes URL
	└─ README.md	
	└─ requirements.txt	
	└─ demo.mov	# vídeo demonstrativo

4. Cronograma resumido

Etapa	Onde	Estimativa
1 — Planejamento	Local	feita
2 — Corpus	Local	2 h
3 — Limpeza + Q&A	Local	3 h (geração ~30 min de cota Gemini)
4 — Chunking + embeddings	Local	1 h
5 — Fine-tuning	Colab T4	1–2 h treino + 1 h prep
6 — Avaliação	Colab	1 h
7 — Chatbot	Colab	1 h
8 — Relatório + vídeo	Local	2 h
Total		~12 h efetivas

5. Riscos identificados

1. **Acesso ao Llama 3.2 — gated.** A licença Meta exige solicitação no HF Hub. Ação: solicitar acesso já no início da Etapa 2.
2. **Cota free do Gemini para Q&A.** 1000 req/dia no `flash-lite`. Mitigação: gerar pares em batch ao longo de 1–2 dias se necessário; reaproveitar pares entre chunks adjacentes.
3. **GPU T4 do Colab pode desconectar.** Mitigação: salvar checkpoint a cada N steps no Drive; rodar em sessões de no máximo 8 h.
4. **PDFs de certificação podem ter texto digitalizado (OCR).** Mitigação: usar PyMuPDF (já validado na GenAI) e fallback para `pytesseract` se necessário. Documentos brasileiros oficiais (LEED Brasil, GBC) costumam ter PDF nativo.

Etapa 3 — Relatório de extração e limpeza do corpus

Documentos processados: 15

id	doc	paginas	cab/rod removidos	palavras	ch
A1	A1_leed_v41_bdc.pdf	163	6	41,266	293,
A2	A2_leed_v4_bdc_pt.pdf	183	5	55,720	372,
A3	A3_inic_inmetro_2020.pdf	159	0	47,791	306,
A4	A4_rtq_r_inmetro_2012.pdf	137	1	30,420	187,
A5	A5_selo_casa_azul_caixa.pdf	204	1	67,412	460,
B1	B1_epe_ben_sintese_2023.pdf	65	0	313	2,
B2	B2_procel_inic_edificacoes_2022.pdf	44	0	6,141	38,
B3	B3_irena_future_solar_pv_summary_2019.pdf	8	3	1,868	12,
B4	B4_scielo_esa_agua_pluvial_hospital_2020.pdf	12	23	6,515	41,
B5	B5_uepg_agua_pluvial_edificacao_comercial_2013.pdf	8	3	2,237	14,
C1	C1_cresesb_manual_fotovoltaiico.pdf	530	0	150,367	976,
C2	C2_labeeee_aquecimento_solar.pdf	61	0	17,169	115,
C3	C3_aneel_micro_minigeracao_distribuida.pdf	32	0	5,298	34,
C4	C4_cbic_guia_conservacao_agua_nbr15527.pdf	160	0	34,229	235,
C5	C5_ipt_reuso_aguas_cinzas.pdf	32	1	3,147	19,

Total: 15 documentos, 469,893 palavras limpas.

Etapa 4 — Relatório de chunking e embeddings

- **Total de chunks:** 2523
- **Tamanho medio:** 401 tokens (alvo 512, sobreposicao 25%)
- **Modelo de embedding:** `intfloat/multilingual-e5-large` (1024 dim, normalizado, cosine)
- **Banco vetorial:** ChromaDB persistente, colecao `edificios_verdes`

Distribuição por categoria

categoria	chunks
certificacao	1292
manual_tecnologia	1143
relatorio_tecnico	88

Distribuição por subcategoria

subcategoria	chunks
energia	1402
ambos	854
agua	267

Distribuição por documento

doc	chunks
A1	175
A2	303
A3	263
A4	175
A5	376

B2	35
B3	7
B4	34
B5	12
C1	807
C2	87
C3	28
C4	205
C5	16

--	--

--	--