

ASSISTENTE PARA PROJETO DE EDIFÍCIOS EFICIENTES QUANTO A ÁGUA E ENERGIA

Refletir sobre o contexto da nova economia espacial é uma grande meta, a qual deveria ser iniciada pensando e tratando problemas simples e comuns enfrentados todos os dias pelos habitantes deste planeta. O consumo exagerado sem crivos de eficiência, economia e reuso de benefícios simples como água e energia nos obriga a repensar como otimizar o uso destes insumos dos quais nossas vidas tanto dependem, para então aplicar estes novos padrões em futuros desbravamentos espaciais. Embora existam atualmente diversas certificações ambientais e regras para construção verde e sustentável, a crescente disponibilidade de documentos técnicos sobre o tema contrasta com a dificuldade de encontrar respostas precisas e rastreáveis. Modelos de linguagem generalistas como GPT, Claude e Llama conhecem superficialmente conceitos como LEED, AQUA-HQE e Net Zero, mas falham ao ser questionados sobre requisitos normativos específicos. Quando o objetivo é criar uma ferramenta especialista, operando em ambiente privado e sem acesso externo, o fine tuning permite modificar os pesos do modelo e incorporar permanentemente o conhecimento do domínio — tornando o assistente intrinsecamente especializado, não apenas aumentado por consulta.

Seu objetivo neste desafio é construir, do zero, um **chatbot especialista em Edifícios Verdes e Net Zero de Energia e Água**, capaz de responder perguntas técnicas com precisão e profundidade. O sistema será construído sobre um LLM de pequeno porte submetido a fine tuning com os dados do corpus construído pelo próprio aluno. O projeto poderá ser executado em ambiente local ou em nuvem, a critério do aluno — recomenda-se o Google Colab com GPU T4.

***Importante:** as documentações escolhidas deverão orientar o interessado em como projetar e operar edifícios sustentáveis capazes de coletar e tratar água localmente e gerar energia via módulos fotovoltaicos ou outro sistema de geração, de modo que o edifício seja capaz de suprir metade ou todas suas necessidades de água e energia sem depender de fontes externas.*

O projeto integra os conceitos estudados em aula: construção de corpus, pré-processamento, chunking, geração de embeddings, indexação em banco vetorial, fine tuning com LoRA ou QLoRA e implantação do modelo ajustado em interface conversacional. O projeto deverá seguir a seguinte estrutura:

1 — Planejamento e escopo Definir o recorte temático dentro do universo de edifícios verdes e Net Zero — por exemplo, focar em eficiência energética, certificações, reúso de água ou em todos simultaneamente. Documentar a decisão e justificar as escolhas de tecnologia: modelo base escolhido para fine tuning, modelo de embedding, banco vetorial, estratégia de ajuste (LoRA, QLoRA ou Full) e hiperparâmetros previstos. Recomenda-se o Llama 3.2 3B como modelo base por seu tamanho compatível com a GPU T4 e bom desempenho em português técnico.

2 — Construção do Corpus Reunir no mínimo 10 documentos técnicos sobre o tema, nos formatos PDF, TXT, DOCX ou HTML. O corpus deve contemplar ao menos três categorias distintas de fonte: normas ou guias de certificação (LEED, AQUA-HQE, GBC Brasil, ABNT NBR 15575), relatórios técnicos ou científicos (IEA, PROCEL, CBCS, artigos de periódicos) e manuais ou especificações de tecnologias habilitadoras (sistemas fotovoltaicos, BEMS, reaproveitamento de águas cinzas). Cada documento deve receber metadados mínimos: fonte, categoria, subcategoria (energia ou água), ano e indicação de vigência.

3 — Limpeza e normalização Extrair o texto de cada documento, remover ruídos típicos de PDFs técnicos — cabeçalhos e rodapés repetidos, números de página, referências bibliográficas isoladas — e normalizar encoding, espaços múltiplos e caracteres especiais. Preservar intactas as tabelas de parâmetros técnicos e os requisitos normativos numerados, pois fragmentá-los compromete a qualidade do ajuste do modelo. A partir do texto limpo, gerar pares de pergunta e resposta que

servirão como conjunto de treinamento para o fine tuning — recomenda-se entre 500 e 1500 pares, cobrindo os principais tópicos do corpus.

4 — Segmentação (chunking) e embeddings Segmentar os documentos em chunks de 512 a 1024 tokens, respeitando a estrutura semântica — seções, artigos e créditos de certificação não devem ser cortados no meio. Aplicar sobreposição de 20 a 30% entre chunks adjacentes para preservar contexto. Gerar embeddings para todos os chunks usando um modelo open-source adequado ao português técnico (recomenda-se `intfloat/multilingual-e5-large` ou `sentence-transformers/paraphrase-multilingual-mpnet-base-v2`) e indexar os vetores em um banco vetorial com persistência em disco — recomenda-se ChromaDB ou FAISS — armazenando os metadados junto a cada chunk. Gerar um relatório com total de chunks, distribuição por categoria e tamanho médio em tokens.

5 — Fine tuning da LLM Aplicar fine tuning supervisionado no modelo base escolhido utilizando os pares de pergunta e resposta gerados na Etapa 3. Definir e justificar a estratégia de ajuste: LoRA ou QLoRA são recomendados para rodar dentro dos limites da GPU T4 com uso de quantização em 4 bits via `bitsandbytes`. Configurar os hiperparâmetros principais — taxa de aprendizado, número de épocas, tamanho do batch, rank LoRA (r) e alpha — documentando as escolhas. Usar a biblioteca `transformers` com `trl` (SFTTrainer) ou `unsloth` para acelerar o treinamento. Salvar o adaptador LoRA treinado para uso posterior.

6 — Avaliação do modelo ajustado Formular 10 perguntas técnicas sobre o corpus coletado e registrar as respostas do modelo após o fine tuning. Comparar essas respostas com as do modelo base original (sem ajuste) nas mesmas 10 perguntas, documentando as diferenças em precisão, profundidade técnica e adequação ao domínio. Calcular pelo menos uma métrica automática de qualidade — BLEU, ROUGE-L ou BERTScore — comparando as respostas geradas com respostas de referência escritas pelo aluno. Analisar os casos em que o modelo ajustado ainda falha e levantar hipóteses sobre as causas.

7 — Chatbot Implantar o modelo ajustado em uma interface conversacional funcional. O chatbot deve manter histórico da conversa dentro da sessão, aceitar perguntas em linguagem natural sobre edifícios verdes e Net Zero, e apresentar as respostas de forma clara e estruturada. Recomenda-se Streamlit ou Gradio para a interface. O sistema pode, opcionalmente, combinar o modelo fine tunado com o banco vetorial construído na Etapa 4 — neste caso, o contexto recuperado complementa o conhecimento incorporado pelo fine tuning.

8 — Relatório crítico Elaborar um relatório técnico analisando: dificuldades encontradas na coleta e preparação dos dados de treinamento; impacto observado do fine tuning na qualidade das respostas em comparação com o modelo base; análise das métricas calculadas; limitações identificadas no modelo ajustado; e proposta de pelo menos duas melhorias que seriam implementadas com mais tempo ou recursos computacionais.

Critérios de Avaliação

Qualidade do notebook contendo corpus, pré-processamento, chunking, embeddings, indexação e fine tuning	30%
Qualidade do modelo ajustado e do chatbot implantado	30%
Relatório crítico com avaliação das 10 perguntas e comparação modelo base vs modelo fine tunado	20%
Vídeo apresentando a solução	20%