

Monitoramento Inteligente de Áreas de Preservação e Supressão Vegetal com Visão Computacional

Contexto do desafio

O monitoramento de áreas de vegetação natural é uma atividade essencial para a preservação ambiental, o controle de queimadas, a identificação de regiões de risco e o acompanhamento de áreas sujeitas à supressão vegetal. Em muitos cenários, esse controle é feito a partir de imagens aéreas, imagens de satélite, mapas georreferenciados e dados de sensoriamento remoto, permitindo observar grandes extensões territoriais de forma mais rápida, escalável e precisa.

Neste desafio, os alunos deverão atuar como uma equipe de Visão Computacional responsável por construir uma solução inteligente para apoiar o **mapeamento e controle de áreas de preservação de vegetação natural**, bem como o monitoramento de regiões com risco de degradação, queimadas ou supressão vegetal. O objetivo é utilizar imagens de satélite para treinar um modelo capaz de identificar padrões visuais associados à presença ou ausência de risco de incêndio florestal, contribuindo para ações preventivas e para a tomada de decisão ambiental.

Base de dados

Os grupos deverão utilizar o dataset **Wildfire Prediction Dataset**, disponível no Kaggle:

Dataset: Wildfire Prediction Dataset

Fonte: Kaggle

Link: <https://www.kaggle.com/datasets/abdelghaniaaba/wildfire-prediction-dataset/data>

A base contém imagens de satélite com resolução de **350x350 pixels**, divididas em duas classes:

Wildfire: imagens associadas a áreas com ocorrência de incêndio florestal.

No Wildfire: imagens associadas a áreas sem ocorrência de incêndio florestal.

O conjunto possui aproximadamente **22.710 imagens da classe Wildfire** e **20.140 imagens da classe No Wildfire**. Os dados já estão organizados em conjuntos de **treino, validação e teste**, com divisão aproximada de 70% para treino, 15% para validação e 15% para teste.

As imagens foram extraídas a partir de coordenadas de latitude e longitude de pontos com ocorrência de incêndio, utilizando imagens de satélite obtidas por API, criando um formato adequado para treinamento de modelos de deep learning voltados à classificação de risco.

Objetivo do projeto

O objetivo principal do projeto é desenvolver um modelo de **classificação de imagens de satélite** capaz de identificar se uma determinada região apresenta características associadas à ocorrência ou ao risco de incêndio florestal. A partir desse modelo, os alunos deverão propor uma aplicação de Visão Computacional voltada ao monitoramento ambiental, auxiliando no controle de áreas de preservação vegetal e no acompanhamento de regiões vulneráveis à supressão ou degradação da vegetação.

A solução deverá explorar conceitos de **sensoriamento remoto, processamento de imagens, redes neurais convolucionais e aprendizado profundo**. Espera-se que os alunos compreendam o problema ambiental, analisem a estrutura do dataset, treinem modelos de classificação e interpretem os resultados obtidos.

Etapas obrigatórias

Os alunos deverão iniciar o projeto compreendendo o problema de monitoramento ambiental e sua relação com o uso de imagens de satélite. A equipe deverá explicar como técnicas de Visão Computacional e sensoriamento remoto podem apoiar a identificação de áreas críticas, regiões de risco, queimadas e possíveis mudanças na cobertura vegetal.

Em seguida, os grupos deverão realizar uma análise inicial da base de dados, verificando a organização das pastas de treino, validação e teste, a quantidade de imagens por classe, o tamanho das imagens, exemplos visuais de cada categoria e possíveis diferenças visuais entre áreas classificadas como **Wildfire** e **No Wildfire**.

Depois, os alunos deverão preparar os dados para treinamento do modelo. Essa etapa pode incluir redimensionamento das imagens, normalização dos pixels, criação de geradores de imagem, data augmentation e separação adequada entre dados de treino, validação e teste. É importante que o conjunto de teste seja utilizado apenas para avaliação final do modelo.

Na etapa de modelagem, os grupos deverão treinar pelo menos **um modelo de classificação de imagens**. A equipe poderá construir uma CNN simples do zero ou utilizar um modelo pré-treinado por meio de **transfer learning**, como MobileNet, ResNet, EfficientNet, VGG ou outro modelo adequado. O uso de modelos pré-treinados é recomendado, pois aproxima o projeto de práticas reais de Visão Computacional aplicada.

A avaliação do modelo deverá considerar métricas adequadas para classificação binária, como **acurácia, precisão, recall, F1-score, matriz de confusão e curva ROC AUC**, quando aplicável. Os alunos deverão interpretar os resultados, explicando os tipos de erro cometidos pelo modelo, especialmente falsos negativos, que neste contexto representam áreas de risco não identificadas corretamente.

Por fim, cada grupo deverá propor como o modelo poderia ser integrado a uma solução real de monitoramento ambiental. Essa proposta pode incluir um painel visual com mapas, alertas automáticos, integração com imagens de satélite periódicas, apoio à fiscalização ambiental ou acompanhamento de áreas de preservação e supressão vegetal.

Formação dos grupos

O trabalho deverá ser realizado em grupos de até **3 integrantes**.

Entregáveis

Cada grupo deverá entregar um **notebook no Google Colab** contendo todo o desenvolvimento do projeto, incluindo carregamento da base, visualização das imagens, preparação dos dados, treinamento do modelo, avaliação dos resultados e conclusão.

Além do código, cada grupo deverá entregar um **vídeo curto de até 3 minutos** explicando o projeto. O vídeo deve apresentar o problema ambiental, a base utilizada, a estratégia de Visão Computacional adotada, o modelo treinado, os principais resultados obtidos e uma breve explicação de como a solução poderia apoiar o monitoramento de áreas de preservação e controle de supressão vegetal.

Critérios de avaliação

A avaliação do projeto será composta pelos seguintes critérios:

Compreensão do problema ambiental e contextualização da solução — 15%

Será avaliada a capacidade do grupo de compreender o problema de monitoramento de áreas de preservação, controle de supressão vegetal e identificação de regiões com risco de incêndio ou degradação ambiental. O grupo deverá relacionar claramente o problema com o uso de sensoriamento remoto e Visão Computacional.

Utilização correta do dataset — 15%

Será avaliada a correta utilização do dataset indicado, incluindo organização das imagens, compreensão das classes **Wildfire** e **No Wildfire**, separação adequada entre treino, validação e teste, além da análise inicial da quantidade e estrutura dos dados.

Pré-processamento e preparação das imagens — 15%

Será considerada a qualidade das etapas de preparação dos dados, como redimensionamento das imagens, normalização dos pixels, data augmentation, criação dos conjuntos de entrada para o modelo e cuidados para evitar vazamento de dados entre treino, validação e teste.

Escolha, implementação e treinamento do modelo de Visão Computacional — 20%

Será avaliada a escolha do modelo utilizado, seja uma CNN construída do zero ou uma abordagem com transfer learning. O grupo deverá justificar a escolha, implementar corretamente o treinamento e demonstrar domínio básico sobre a arquitetura utilizada.

Avaliação do modelo e interpretação das métricas — 15%

Será avaliada a utilização de métricas adequadas para classificação binária, como acurácia, precisão, recall, F1-score, matriz de confusão e ROC AUC, quando aplicável. O grupo deverá interpretar os resultados obtidos, discutindo acertos, erros e limitações do modelo.

Organização do notebook e qualidade do código — 10%

Será considerada a clareza do notebook no Google Colab, a organização das seções, a legibilidade do código, o uso adequado de comentários e a facilidade de reprodução dos experimentos.

Apresentação final em vídeo — 10%

Será avaliada a clareza do vídeo de até 3 minutos, incluindo a explicação do problema, da base utilizada, da estratégia de modelagem, dos principais resultados e da aplicação da solução no contexto de monitoramento ambiental.